

DollarPunk

ETL-NLP per il monitoraggio del sentiment
e il supporto decisionale in finanza comportamentale

Alessandro Beninati

18 luglio 2026

Indice

1	Motivazione	3
2	Stato dell'arte	4
2.1	Social media e sentiment degli investitori	4
2.2	L'avvento dei modelli Transformer e di FinBERT	4
2.3	Modelli di linguaggio generali vs. specifici in finanza	5
2.4	Instruction tuning e preference optimization	5
2.5	Benchmark e valutazione sistematica	6
2.6	Agenti LLM e validità empirica delle strategie	6
2.7	Interazioni tra notizie, grafi e diffusione	7
2.8	Sintesi e tendenze	7
3	Descrizione del progetto	8
3.1	Strumenti di sviluppo, versioning e hosting	8
3.2	Raccolta dati	8
3.3	Analisi dati testuali	8
3.3.1	Tickers	9
3.3.2	Relevance score	9
3.3.3	Sentiment score	9
3.3.4	Fine-tuning e RAG	9
3.3.5	Sintesi	9
3.4	Decay temporale (solo sul relevance)	10
3.4.1	Sviluppi futuri: diffusione semantica	11
3.5	Analisi esplorativa: sentiment e prezzo	11
3.5.1	Backtesting e simulazione di portafoglio	11
3.5.2	Integrazione con modelli predittivi	11
4	Stato dell'implementazione	12
4.1	Architettura e stack tecnologico	12
4.2	Raccolta dati	12
4.3	Persistenza e modello dati	12
4.3.1	Archiviazione cold-storage	13
4.4	Scoring del sentiment: delega al provider	13
4.5	Decay temporale e KPI di sentiment	13
4.6	Indicatori di analisi tecnica	14
4.7	Interfaccia web e funzionalità utente	14
4.8	Confronto sintetico: previsto vs. implementato	14
4.9	Prossimi passi	15

5	Direzioni future	17
5.1	Direzioni per la ricerca	17
5.1.1	Stima empirica del parametro di decay	17
5.1.2	Diffusione semantica: dalla PDE alla soluzione discreta	17
5.1.3	Benchmark multi-scorer del sentiment	18
5.1.4	Attenzione mediatica come segnale complementare	19
5.1.5	Interazione tra sentiment e segnali tecnici	19
5.1.6	Notizie programmate e non programmate	19
5.1.7	Foundation model per serie temporali	19
5.1.8	Protocollo di backtesting metodologicamente rigoroso	20
5.2	Direzioni per l'applicativo	20
5.3	Sintesi	20

1 Motivazione

Ogni giorno i mercati finanziari vengono raccontati da un flusso di testo—notizie, comunicati, analisi, discussioni social—che eccede di ordini di grandezza la capacità di lettura di qualunque analista. La letteratura ha mostrato che questo flusso contiene informazione predittiva misurabile (Capitolo 2), e l'industria lo ha trasformato in prodotti commerciali di *news analytics*. Questi sistemi, tuttavia, sono opachi: punteggi di sentiment e di rilevanza vengono forniti come scatole nere, con parametri (ad esempio il decadimento temporale dell'informazione) fissati e non ispezionabili, e le interazioni tra notizie relative ad aziende collegate sono generalmente ignorate o delegate a modelli non interpretabili.

La presente proposta nasce dall'incrocio tra questa osservazione e la mia esperienza professionale: tre anni in consulenza informatica nel campo dell'ingegneria dati, tra processi ETL e migrazioni cloud per grandi aziende italiane, mi hanno insegnato quanto valore analitico resti intrappolato nei dati non strutturati e quanto conti disporre di pipeline trasparenti e verificabili.

L'obiettivo è quindi duplice. Sul piano applicativo, sviluppare un sistema aperto che raccolga notizie finanziarie, ne aggregi il sentiment per titolo con un modello di decadimento temporale esplicito e parametrizzabile, e lo esponga accanto ai segnali di prezzo. Sul piano scientifico, colmare un vuoto specifico della letteratura: la modellazione della rilevanza informativa come *campo dinamico* che decade nel tempo e si *diffonde* tra titoli semanticamente collegati, formulata in modo interpretabile—con parametri fisicamente leggibili e garanzie formali di correttezza—anziché appresa da architetture black-box. Il prototipo operativo descritto nel Capitolo 4 costituisce l'infrastruttura di dati e validazione su cui queste domande possono essere testate empiricamente.

2 Stato dell'arte

Il ruolo del sentiment degli investitori nei mercati è stato formalizzato da Baker e Wurgler (2007), che ne hanno mostrato l'effetto sistematico sui rendimenti trasversali, in particolare sui titoli difficili da valutare e da arbitraggiare. Sul fronte testuale, lo studio pionieristico è quello di Tetlock (2007): quantificando il “pessimismo” degli articoli del *Wall Street Journal*, Tetlock ha rilevato che livelli elevati di tono negativo nella stampa anticipano pressioni al ribasso sui prezzi azionari, seguite da un ritorno ai fondamentali. La generazione successiva di lavori lessicali ha mostrato l'importanza della specializzazione di dominio: Loughran e McDonald (2011) dimostrano che i dizionari generici classificano erroneamente come negativo quasi i tre quarti delle parole “negative” nei documenti finanziari (es. *liability*, *cost*), introducendo il lessico finanziario che porta il loro nome e che resta un riferimento standard. Questi risultati hanno fornito l'evidenza empirica di base: il tono dei testi finanziari contiene informazione sui movimenti di mercato, purché estratto con strumenti adeguati al dominio.

2.1 Social media e sentiment degli investitori

Con la diffusione dei social media negli anni 2010, le fonti di dati sul sentiment si sono ampliate: gli investitori retail hanno iniziato a esprimere opinioni su forum finanziari, Twitter e blog, generando un flusso testuale in tempo reale. Il lavoro che ha catalizzato l'interesse del settore è quello di Bollen, Mao e Zeng (2011), secondo cui specifiche dimensioni dell'umore collettivo estratte da Twitter anticipano le variazioni del Dow Jones. In seguito McGurk, Nowak e Hall (2020), costruendo una misura quantitativa del sentiment degli investitori dai post social, rilevano un effetto positivo e significativo sui rendimenti anomali—in tensione con la teoria finanziaria tradizionale, che tende a escludere i fattori emotivi.

Un caso emblematico che ha catalizzato l'interesse sull'analisi del sentiment è la pandemia di COVID-19. Duan, L. Liu e Z. Wang (2021), tra gli altri, sviluppano indici di sentiment legati al COVID-19 utilizzando milioni di testi provenienti sia dai media ufficiali sia dai social in Cina.

2.2 L'avvento dei modelli Transformer e di FinBERT

Alla fine degli anni 2010, l'introduzione di BERT (Devlin et al. 2019) ha rivoluzionato l'NLP anche in ambito finanziario, grazie a rappresentazioni linguistiche contestuali di alta qualità. Tuttavia, l'adattamento al linguaggio tecnico della finanza ha richiesto modelli specializzati. FinBERT, proposto da Araci (2019), è stato tra i primi modelli pre-addestrati su testi finanziari e successivamente fine-tunati per la sentiment analysis, superando di circa 15 punti percentuali i metodi precedenti su dataset come *Financial PhraseBank*.

Versioni successive, come quella di Huang, H. Wang e Y. Yang (2023), addestrate su ampi corpora finanziari, hanno raggiunto fino all'89,7% di accuratezza nel rilevare frasi negative, migliorando la comprensione delle sfumature linguistiche rispetto ai modelli generici.

FinBERT è oggi uno standard per task NLP finanziari: analisi del tono nei report, classificazione di notizie, estrazione di informazioni da bilanci. Gu et al. (2024) mostrano che un modello FinBERT+LSTM migliora la previsione dei trend azionari rispetto a LSTM tradizionali, evidenziando il valore della specializzazione di dominio.

Infine, l'emergere di benchmark specifici (es. FiQA, Financial PhraseBank) ha supportato valutazioni comparative, mentre estensioni recenti si concentrano su analisi a livello di entità (Yixuan Tang et al. 2023).

2.3 Modelli di linguaggio generali vs. specifici in finanza

Nel 2022–2023, l'attenzione si è spostata sui LLM generici come ChatGPT (GPT-3.5/4), capaci di interpretare testi finanziari nonostante l'assenza di addestramento settoriale. Lopez-Lira e Yuehua Tang (2025)—in pubblicazione sul *Journal of Financial Economics*—mostrano che GPT-4 può prevedere la direzione dei prezzi azionari dai soli titoli delle notizie, con capacità che cresce con la dimensione del modello e rendimenti della strategia che si riducono man mano che l'adozione dei LLM aumenta, coerentemente con un miglioramento dell'efficienza dei prezzi. Anche in modalità zero-shot, modelli come GPT-3.5/4 riescono a svolgere sentiment analysis su documenti finanziari, pur con limiti su contesti specialistici o eventi recenti (Shobayo et al. 2024).

Questi risultati hanno spinto verso LLM specializzati. BloombergGPT (Wu et al. 2023), con 50 miliardi di parametri e un corpus di 363 miliardi di token finanziari, è tra i primi LLM su larga scala dedicati alla finanza, con maggiore precisione su prompt settoriali grazie alla conoscenza approfondita del dominio.

In parallelo, il progetto open-source FinGPT (H. Yang, X.-Y. Liu e C. D. Wang 2023) punta a rendere i LLM finanziari accessibili, attraverso fine-tuning di modelli open-source su dati finanziari pubblici. Con un approccio *data-centric*, FinGPT abilita analisi di sentiment, generazione automatica di report e sviluppo low-code, pur operando con risorse più contenute rispetto ai modelli proprietari.

2.4 Instruction tuning e preference optimization

Una direzione che si è consolidata dal 2023 è l'*instruction tuning* di LLM open-weight su compiti finanziari. Il progetto PIXIU (Xie, Han, Xiao Zhang et al. 2023) introduce FinMA, un modello basato su LLaMA e affinato su 136.000 istruzioni finanziarie multi-task, insieme al primo benchmark standardizzato di valutazione (FLARE). I modelli instruction-tuned di dimensioni contenute eccellono nei task di sentiment classification (Financial PhraseBank, FiQA-SA), pur generalizzando peggio dei grandi modelli proprietari su compiti di ragionamento complesso.

Il paradigma più recente supera il fine-tuning supervisionato (SFT) con tecniche di *preference alignment*. FinDPO (Iacovides, Zhou e Mandic 2025) applica la Direct Preference Optimization a un LLM causale per la sentiment analysis finanziaria, superando in media dell'11% i modelli SFT esistenti sui benchmark standard. Di particolare interesse per questo progetto è la conversione *logit-to-score* proposta dagli autori: le predizioni discrete di

sentiment vengono trasformate in punteggi continui e ordinabili (probabilità), direttamente integrabili in strategie di portafoglio—un’idea affine al *sentiment score* continuo adottato nella presente proposta. Nelle simulazioni riportate, la strategia basata su FinDPO mantiene rendimenti positivi anche in presenza di costi di transazione realistici.

Più in generale, diversi lavori del 2024–2025 mostrano che LLM open-weight recenti (LLaMA 3, Qwen, DeepSeek), anche con fine-tuning leggero, superano stabilmente FinBERT nella classificazione del sentiment finanziario, rendendo lo scoring di qualità accessibile senza infrastrutture proprietarie.

2.5 Benchmark e valutazione sistematica

La proliferazione di modelli ha reso centrale il problema della valutazione. FinBen (Xie, Han, Chen et al. 2024) è il primo benchmark open-source su larga scala per LLM finanziari: 36 dataset su 24 task, che coprono estrazione di informazioni, analisi testuale, question answering, generazione, gestione del rischio, previsione e decision-making, incluse valutazioni di agenti e di pipeline RAG. I risultati confermano che i LLM eccellono nell’analisi testuale (incluso il sentiment) ma faticano su ragionamento avanzato e previsione.

In parallelo emergono cautele metodologiche. Shobayo et al. (2024) mostrano che un semplice modello di regressione logistica ha superato FinBERT e GPT-4 in accuratezza su un task di sentiment, segnalando che maggiore complessità non implica necessariamente migliori performance. Inoltre, benchmark storici come Financial PhraseBank risultano ormai prossimi alla saturazione e potenzialmente presenti nei dati di pre-training dei modelli più recenti, sollevando dubbi di contaminazione che spingono verso dataset di valutazione nuovi, a livello di entità (Yixuan Tang et al. 2023) e temporalmente successivi al cutoff dei modelli.

2.6 Agenti LLM e validità empirica delle strategie

Dal 2024 la frontiera si è spostata dagli score di sentiment ai sistemi *agentici*, in cui più LLM con ruoli specializzati collaborano al processo decisionale. TradingAgents (Xiao et al. 2025) simula una società di trading con agenti analisti (fondamentale, sentiment, tecnico), ricercatori bull/bear in dibattito, trader e risk manager, riportando miglioramenti su rendimento cumulato, Sharpe ratio e drawdown massimo. Framework analoghi (FinMem, FinCon, FinRobot, MarketSenseAI) integrano memoria episodica, retrieval di notizie e analisi multi-fonte.

A questi risultati promettenti si contrappone una crescente letteratura critica sulla loro validità empirica. Li et al. (2026) propongono FINSABER, un framework di backtesting che valuta le strategie LLM su oltre vent’anni e più di cento titoli, controllando *survivorship bias*, *look-ahead bias* e *data-snooping*: i vantaggi riportati in letteratura si riducono drasticamente su orizzonti lunghi e universi ampi, con strategie troppo conservative nei mercati rialzisti e troppo aggressive in quelli ribassisti. Un’insidia specifica dei LLM è inoltre il look-ahead bias “parametrico”: un modello con cutoff di addestramento recente ha già osservato gli anni coperti dal backtest, e questa conoscenza—incorporata nei pesi—è invisibile ai controlli

sulla pipeline dei dati. Queste evidenze rendono il disegno sperimentale del backtesting (Capitolo 3) un aspetto metodologicamente critico, non un dettaglio implementativo.

2.7 Interazioni tra notizie, grafi e diffusione

Un ulteriore filone, direttamente rilevante per la proposta di diffusione semantica di questo progetto, abbandona l'ipotesi che le notizie agiscano in modo indipendente. Wan et al. (2021) mostrano che il sentiment si diffonde lungo reti di notizie tra aziende collegate, con effetti misurabili sui movimenti di mercato; M. Wang, Cohen e Ma (2024) introducono FININ, che modella esplicitamente le interazioni semantiche tra notizie per la previsione dei mercati. Più recentemente, architetture a grafo con meccanismi di diffusione dell'informazione (graph neural network su relazioni tra titoli, reti di *sentiment spillover* stimate via transfer entropy) integrano segnali testuali e struttura relazionale del mercato, confermando che la propagazione cross-asset dell'informazione è un segnale predittivo autonomo. La formulazione continua a derivate parziali proposta nel Capitolo 3 si colloca in questo filone, ma con un approccio interpretabile e ancora poco documentato in letteratura.

2.8 Sintesi e tendenze

Nuove metriche ampliano infine le prospettive oltre la polarità del tono: Cao, Wunkaew e Geman (2025) propongono l'Hype Index, che misura l'attenzione mediatica anziché il sentiment. Analizzando l'S&P 100, dimostrano che un picco di copertura può anticipare volatilità e movimenti di mercato, sottolineando il valore dell'"intensità" informativa come fattore predittivo.

In sintesi, dal 2007 a oggi l'evoluzione è passata dalle analisi lessicali (Tetlock, Loughran-McDonald) ai modelli specializzati (FinBERT), ai LLM generici e finanziari (BloombergGPT, FinGPT), fino a instruction tuning e preference optimization (FinMA, FinDPO), sistemi agentici (TradingAgents) e benchmark olistici (FinBen). Le tendenze attuali puntano su punteggi continui integrabili in strategie, valutazione rigorosa e priva di bias temporali, analisi a livello di entità e modelli che considerano non solo il sentiment, ma anche attenzione mediatica, interazioni tra notizie e struttura relazionale del mercato.

3 Descrizione del progetto

3.1 Strumenti di sviluppo, versioning e hosting

Il progetto adotta un approccio rapido e sperimentale, supportato da strumenti AI per refactoring e generazione di codice sotto supervisione umana, con codice versionato su GitHub. L'ambiente di sviluppo locale è containerizzato con Docker; la produzione è su PaaS (Heroku), scelta all'esito della valutazione tra PaaS e VPS prevista dalla proposta originaria. Per il training futuro si prevede il ricorso a GPU cloud (es. RunPod). Il prototipo attuale è interamente in Python—Flask e PostgreSQL, affiancati dal cold store DuckDB per lo storico—come documentato nel Capitolo 4; una demo pubblica è disponibile all'indirizzo <https://dollarpunk-26786f215068.herokuapp.com/dashboard>.

3.2 Raccolta dati

La previsione dei movimenti di mercato richiede grandi volumi di dati testuali da fonti eterogenee: testate finanziarie (Bloomberg, Reuters, WSJ, Yahoo Finance, ANSA, Il Sole 24 Ore), social media e community (Twitter, Reddit—con relative metriche di engagement—, Telegram, YouTube) e motori di ricerca (SerpApi, **ddgs**), su temi che spaziano dal sentiment finanziario ai trend macroeconomici, earning report, ESG e criptovalute. L'acquisizione avverrà via API quando possibile e via scraping (es. libreria **newspaper**) altrimenti, con una strategia comune di strutturazione dei dati.

3.3 Analisi dati testuali

Il nucleo della pipeline è una funzione che elabori un testo e restituisca un oggetto strutturato con i ticker menzionati e, per ciascuno, un *relevance score* e un *sentiment score*:

```
1 {  
2   "title": "If You Invested $1,000 In Lululemon Stock In 2013...",  
3   "source": "Motley Fool",  
4   "time_published": "2023-04-30T13:34:00",  
5   "stocks_mentioned": ["LULU", "NKE"],  
6   "ticker_sentiments": [  
7     {"ticker": "NKE", "relevance_score": 0.27,  
8       "sentiment_score": 0.22, "sentiment": "Somewhat-Bullish"}  
9   ]  
10 }
```

Di seguito le soluzioni valutate per il calcolo affidabile dei tre campi, in un settore in cui strumenti più efficaci possono emergere anche nel breve termine.

3.3.1 Tickers

L'associazione testo-ticker combina più segnali: contesto della raccolta (query mirate), Named Entity Recognition, pattern matching (`$AAPL`, `(NASDAQ:AAPL)`) e dizionari nome-ticker. Un sistema robusto integra le fonti con un *confidence score*—alto per citazioni dirette, medio per nomi aziendali, basso per riferimenti indiretti—riducendo l'ambiguità dell'associazione.

3.3.2 Relevance score

Il *relevance score* misura quanto un ticker sia centrale nel testo. Il conteggio normalizzato delle occorrenze basta per un prototipo; approcci più contestuali includono i pesi di attenzione dei Transformer, i sistemi commerciali che valutano frequenza, posizione e ruolo semantico (RavenPack 2025c), o l'assegnazione diretta via prompting di un LLM, resa credibile dai risultati di Lopez-Lira e Yuehua Tang (2025) sullo scoring di headline.

3.3.3 Sentiment score

Il *sentiment score* mappa il tono verso un ticker su una scala continua (da -1 a $+1$), tramite modelli specializzati come FinBERT o LLM. Per maggiore precisione si adotta il sentiment a livello di entità (Yixuan Tang et al. 2023), come nei sistemi commerciali (Refinitiv, Bloomberg) e open-source (H. Yang, X.-Y. Liu e C. D. Wang 2023); in alternativa, LLM zero-shot generano punteggi continui via prompt senza training specifico (Shobayo et al. 2024).

3.3.4 Fine-tuning e RAG

Il fine-tuning di un modello open-weight consente di ottenere un sistema che restituisca direttamente l'oggetto strutturato (ticker, relevance, sentiment), unificando la pipeline: candidati naturali sono FinBERT (Araci 2019) e gli LLM open-weight recenti (LLaMA 3, Qwen), affinabili su dataset con etichette a livello di entità—da challenge pubbliche (Maia et al. 2018) o aggregati tramite API di notizie—su GPU cloud. L'alternativa senza addestramento è RAG (Lewis et al. 2020): si indicizza il corpus in una base vettoriale e un LLM genera lo scoring dal contesto recuperato, con il vantaggio dell'aggiornabilità immediata dell'indice.

3.3.5 Sintesi

La scelta operativa dipende da due risorse: il dataset etichettato e la capacità di calcolo. Con un dataset a livello di ticker disponibile—condizione oggi soddisfatta dall'archivio descritto nel Capitolo 4—la via maestra è il fine-tuning supervisionato; in alternativa il RAG evita l'addestramento. In assenza di dataset restano lo zero-shot e l'annotazione manuale o LLM-assistita di un corpus iniziale.

3.4 Decay temporale (solo sul relevance)

Calcolati *tickers*, *sentiment* e *relevance*, i punteggi vanno distribuiti nel tempo per ottenere una misura giornaliera del sentiment attivo. Si applica un decadimento esponenziale al solo *relevance score*—il sentiment resta invariato, ma pesa in proporzione alla rilevanza residua:

$$R_{i,d} = R_{i,0} \cdot e^{-\lambda \Delta t}, \quad S_{i,d} = S_{i,0}, \quad \text{AvgW}_d = \frac{\sum_i S_{i,0} \cdot R_{i,d}}{\sum_i R_{i,d}}$$

dove Δt sono i giorni dalla pubblicazione e λ un parametro di decay da stimare. L’approccio è coerente con i provider commerciali, che applicano decay esponenziali alla rilevanza (RavenPack 2025c; RavenPack 2025b; RavenPack 2025a). Nell’implementazione corrente (Capitolo 4) il decadimento è parametrizzato tramite *emivita* h , con peso $w = 0,5^{\Delta t/h}$: equivalente a $\lambda = \ln(2)/h$, ma direttamente interpretabile.

Esempio

Nella tabella, il relevance viene attenuato giorno per giorno con $\lambda = 0,5$ (la news 2 è pubblicata al giorno 1), mentre il sentiment resta fisso:

News #	Giorno 0	Giorno 1	Giorno 2
1	S=1.000, R=0.800	S=1.000, R=0.485	S=1.000, R=0.294
2	—	S=0.900, R=0.700	S=0.900, R=0.425
3	S=0.750, R=0.600	S=0.750, R=0.364	S=0.750, R=0.221
Media ponderata AvgW_d	≈0.893	≈0.896	≈0.896
Massa attiva $\sum_i R_{i,d}$	1.400	1.549	0.940

L’esempio illustra due proprietà del modello che vale la pena rendere esplicite, perché a prima vista sorprendono.

La prima: la media ponderata *non decade*. Essendo una media dei sentiment osservati con pesi non negativi, AvgW_d resta sempre compresa tra il sentiment minimo e quello massimo delle notizie attive (qui tra 0.75 e 1.0). E finché non arrivano notizie nuove, non cambia affatto: passando da un giorno al successivo ogni peso viene moltiplicato per lo stesso fattore $e^{-\lambda}$, che compare identico al numeratore e al denominatore e quindi si semplifica. Il decadimento sposta la media solo *indirettamente*, cambiando i pesi relativi quando arrivano notizie nuove (più pesanti) accanto a quelle vecchie (più leggere).

La seconda: ciò che decade davvero è la *rilevanza totale* $\sum_i R_{i,d}$, che si contrae esattamente di un fattore $e^{-\lambda}$ al giorno e risale solo all’arrivo di nuove notizie—nella tabella cresce al giorno 1 con la news 2 e si dissipa al giorno 2. Le due grandezze sono complementari: la media misura la *direzione* del sentiment attivo, la rilevanza totale la sua *intensità*, e un segnale operativo completo le richiede entrambe.

3.4.1 Sviluppi futuri: diffusione semantica

Il decadimento tratta ogni notizia come indipendente; in realtà i titoli condividono contesto semantico, e una notizia rilevante per un'azienda dice qualcosa anche sulle aziende affini. L'estensione naturale è quindi lasciare che la rilevanza, oltre a decadere nel tempo, si *propaghi* tra titoli semanticamente vicini—un'idea ancora poco documentata in forma interpretabile nella letteratura NLP-finance, dove i lavori più affini usano reti informative (Wan et al. 2021) o modelli di interazione tra notizie (M. Wang, Cohen e Ma 2024). Il modello completo, con soluzione e proprietà di correttezza, è sviluppato in un'unica sezione nel Capitolo 5 (Sezione 5.1.2).

3.5 Analisi esplorativa: sentiment e prezzo

Dopo raccolta e scoring, va verificato se il sentiment estratto abbia un legame con i prezzi: grafici comparativi sentiment–chiusure, scatter plot con le variazioni percentuali e correlazioni (Pearson, Spearman) anche con ritardi temporali. Studi come Cristescu et al. (2023) rilevano correlazioni significative tra sentiment delle notizie e prezzi di titoli come Apple, Microsoft e Tesla. La fase è iterativa: senza segnali si rivedono dati o scoring; con una relazione anche parziale si procede verso modelli più sofisticati.

3.5.1 Backtesting e simulazione di portafoglio

Il backtesting simula una strategia su dati storici: ad esempio, long se il sentiment è positivo, flat (o short) altrimenti, con ingresso il giorno successivo al segnale. Le metriche di valutazione sono rendimento cumulato contro benchmark, accuratezza direzionale e Sharpe ratio semplificato. L'estensione multi-ticker aggiunge capitale iniziale, allocazione, regole di uscita e costi di transazione: l'obiettivo non è ottimizzare, ma verificare che la strategia regga in condizioni credibili prima di investire in modelli predittivi.

3.5.2 Integrazione con modelli predittivi

Il passo successivo è un modello che utilizzi congiuntamente prezzi, volumi, indicatori tecnici e sentiment su finestre temporali mobili. Le reti LSTM sono lo standard consolidato per la previsione finanziaria (Fischer e Krauss 2018), e diversi studi (Ouf et al. 2024; Gu et al. 2024) mostrano che l'aggiunta del sentiment come variabile esplicativa migliora la previsione rispetto ai soli dati di prezzo, catturando movimenti spiegati dall'informazione testuale. Le alternative fondazionali più recenti sono discusse nel Capitolo 5.

4 Stato dell'implementazione

Questo capitolo documenta lo stato del prototipo operativo, distinguendo le componenti implementate da quelle pianificate.

4.1 Architettura e stack tecnologico

Il prototipo è interamente in **Python**: PostgreSQL per la persistenza, Flask come server web e API REST, Gunicorn per il deploy. La configurazione locale avviene tramite Docker Compose; in produzione l'applicazione è esposta su Heroku (<https://dollarpunk-26786f215068.herokuapp.com/dashboard>). Rispetto al disegno iniziale non sono ancora presenti moduli in altri linguaggi né pipeline di training su GPU: l'approccio privilegia un MVP orientato a ingestion, persistenza e visualizzazione.

4.2 Raccolta dati

La raccolta testuale si appoggia esclusivamente all'endpoint `NEWS_SENTIMENT` di Alpha Vantage: per ogni articolo l'API restituisce metadati (titolo, URL, fonte, timestamp, summary) e, per ciascun ticker menzionato, *relevance score*, *sentiment score* ed etichetta qualitativa, persistiti in database nel formato JSON del provider—coerente con l'output atteso nel Capitolo 3.

L'acquisizione avviene in più modalità, attivabili dalla dashboard amministrativa o da job schedulati: raccolta manuale parametrizzata (ticker, topic, intervallo), *deep ingestion* estesa con tracciamento dello stato, *coverage ingestion* sistematica degli ultimi N giorni su tutti i topic e i ticker noti (con ripresa automatica), e *prune* periodico che mantiene la finestra rolling. Ogni esecuzione è registrata nella tabella `job_executions`.

La raccolta attuale è quindi **monofonte** e dipendente dai limiti di rate dell'API (5 chiamate/minuto nel tier gratuito, 75 nel premium): le fonti eterogenee del Capitolo 3 (social, scraping, motori di ricerca) non sono ancora integrate.

4.3 Persistenza e modello dati

La tabella centrale `articles` memorizza ogni notizia con inserimento **idempotente** sulla chiave `url`. La affiancano: `stock_prices` (chiusure e volumi giornalieri, recuperati lazy e cachati), `companies` (anagrafica e descrizione del business), `company_embeddings` (vettori OpenAI `text-embedding-3-small` delle descrizioni), `company_correlation_matrix` (similitudine coseno tra embedding, cachata) e `job_executions`. Due viste SQL supportano l'analisi: `article_ticker_sentiment_view` espande il JSONB in una riga per coppia (articolo, ticker); `ticker_daily_sentiment_view` aggrega per ticker e giorno con decadimento temporale. Sono predisposte, ma non ancora popolate, le tabelle `ticker_decayed_sentiment` e `ticker_cross_diffused_sentiment`.

4.3.1 Archiviazione cold-storage

La finestra rolling di 30 giorni, imposta dai limiti del piano PostgreSQL in produzione (1 GB), comportava originariamente la perdita definitiva degli articoli rimossi dal prune. È stata quindi introdotta un'architettura a due livelli: il PostgreSQL di produzione come *hot store* (ultimi 30 giorni, serve dashboard e API) e un archivio analitico **DuckDB** su MotherDuck come *cold store*, alimentato quotidianamente e privo di limiti pratici di crescita. Il job di archiviazione copia articoli e prezzi con **inserimento idempotente** tramite anti-join sulla chiave naturale, e nello scheduler precede il prune: nessun articolo viene cancellato prima di essere stato archiviato.

Al bootstrap (luglio 2026) l'archivio conteneva **758 817 articoli** con scoring per ticker—storico dal novembre 2018, recuperato in parte da un'istanza locale—e 24 758 osservazioni di prezzo. Questo dataset è la base empirica per due componenti finora teoriche della proposta: il fine-tuning su coppie (testo, sentiment) già etichettate e il backtesting su orizzonti pluriennali richiesto dal protocollo anti-bias del Capitolo 5.

4.4 Scoring del sentiment: delega al provider

Al momento **non esiste una pipeline NLP proprietaria**: estrazione dei ticker, relevance e sentiment sono calcolati da Alpha Vantage e persistiti così come ricevuti; FinBERT, RAG, fine-tuning e NER proprietario restano da implementare. La scelta ha permesso di validare rapidamente ETL, storage e visualizzazioni, rimandando il modulo NLP a una fase successiva.

4.5 Decay temporale e KPI di sentiment

Il decadimento del Capitolo 3 è operativo, parametrizzato tramite **emivita**. Per ogni ticker, il KPI giornaliero calcolato in dashboard e nelle API pubbliche è:

$$\text{KPI}_d = \frac{\sum_i s_i \cdot r_i \cdot w_i}{\sum_i r_i \cdot w_i}, \quad w_i = 0,5^{\Delta t_i/h}$$

dove s_i e r_i sono sentiment e relevance dell'articolo i , Δt_i i giorni dalla pubblicazione e h l'emivita configurabile (default: 7 giorni), equivalente a $\lambda = \ln(2)/h$.

La stessa logica è replicata nell'endpoint `/api/tickers/<ticker>/sentiment-kpi` e nella pagina portfolio. La vista SQL `ticker_daily_sentiment_view` adotta invece la variante *non normalizzata* (somma decayed dei contributi): come discusso nel Capitolo 3, la media normalizzata misura la *direzione* del sentiment attivo, la somma decayed la sua *intensità*—la coesistenza è una scelta informativa, non una duplicazione.

La diffusione semantica non è ancora operativa; esiste però l'ingrediente chiave: la matrice di similarità coseno tra i profili aziendali (embedding OpenAI), consultabile dalla sezione *Companies*, che non alimenta ancora `ticker_cross_diffused_sentiment`.

4.6 Indicatori di analisi tecnica

Accanto al KPI di sentiment, il prototipo calcola indicatori tecnici classici dalle chiusure già persistite, senza chiamate API aggiuntive: l'obiettivo è affiancare al segnale informativo (“cosa dicono le notizie”) un segnale di prezzo (“cosa sta facendo il titolo”). Benché storicamente controversa, l'analisi tecnica ha una fondazione statistica riabilitata in letteratura: Lo, Mamaysky e J. Wang (2000) mostrano che i pattern tecnici contengono informazione incrementale, e Neely et al. (2014) che gli indicatori tecnici prevedono il premio al rischio con potere comparabile—e complementare—alle variabili macroeconomiche.

- **Medie mobili semplici** a 20 e 50 giorni, con la distanza percentuale dalla SMA 50 come momentum sintetico;
- **Bande di Bollinger** (Bollinger 2001): $SMA_{20} \pm 2\sigma_{20}$, con la posizione del prezzo nella banda normalizzata in $[0, 1]$;
- **RSI a 14 giorni** (Wilder 1978), con soglie convenzionali di ipercomprato (> 70) e ipervenduto (< 30);
- **Volatilità realizzata a 20 giorni**, annualizzata con fattore $\sqrt{252}$.

Gli indicatori sono esposti da un endpoint dedicato e visualizzati come overlay sul grafico prezzo-volume nella pagina di dettaglio e come badge sintetici accanto al KPI di sentiment in dashboard. Sopra di essi è costruito un **report tecnico automatico**: un generatore deterministico a regole che traduce gli indicatori in una lettura testuale (momentum, incroci di medie, ipercomprato/ipervenduto, *squeeze* di volatilità) e la conclude confrontando la direzione tecnica con il KPI di sentiment corrente, segnalandone l'*allineamento* o la *divergenza*. La rilevazione automatica delle divergenze rende osservabile in tempo reale, per ogni titolo, il fenomeno al centro della domanda di ricerca sull'interazione tra i due segnali (Brock, Lakonishok e LeBaron 1992) sviluppata nel Capitolo 5.

4.7 Interfaccia web e funzionalità utente

L'area amministrativa (autenticata) permette di lanciare job di ingestion, consultare statistiche, esplorare articoli, eseguire query SQL e gestire l'anagrafica aziende con vettorizzazione batch. L'area pubblica (read-only) offre la dashboard giornaliera con ranking dei ticker per KPI di sentiment e filtri configurabili; per ogni ticker una pagina di dettaglio con grafico prezzo-volume e indicatori, serie del KPI, ultime notizie e profilo aziendale; la pagina *Portfolio* monitora una watchlist personalizzata con storico prezzi, sentiment decayed e news.

4.8 Confronto sintetico: previsto vs. implementato

La Tabella 4.1 riassume lo scostamento tra proposta e stato corrente del codice.

Componente	Previsto	Stato attuale
Fonti dati	Multi-fonte (news, social, scraping)	Solo Alpha Vantage
NLP / scoring	FinBERT, RAG, fine-tuning	Delegato al provider API
ETL e storage	Pipeline strutturata	Implementato (PostgreSQL)
Archiviazione storico	— (non prevista)	Cold store DuckDB/MotherDuck, 758k articoli dal 2018
Indicatori tecnici	Input per LSTM	SMA, Bollinger, RSI, volatilità in dashboard e API
Decay temporale	$R \cdot e^{-\lambda \Delta t}$	Emivita $0,5^{\Delta t/h}$ in SQL e API
Diffusione semantica	PDE su spazio news	Solo embedding aziende (parziale)
Analisi sentiment-prezzo	Correlazioni Pearson/Spearman	Grafici separati, no statistica
Backtesting	Strategia long/short, Sharpe	Non implementato
Simulazione portafoglio	Capitale, costi, stop-loss	Watchlist + monitoraggio
LSTM predittivo	Prezzo + sentiment	Non implementato
Deploy	Docker, PaaS	Docker + Heroku operativi

Tabella 4.1: Confronto tra componenti previste e stato di implementazione al momento della stesura.

4.9 Prossimi passi

Le priorità di sviluppo coerenti con la proposta sono:

1. introdurre almeno una fonte dati aggiuntiva per ridurre la dipendenza dal singolo provider;
2. implementare un modulo NLP interno (es. FinBERT zero-shot) per confronto con i punteggi Alpha Vantage, sfruttando il dataset del cold store (Sezione 4.3.1);
3. popolare e validare le tabelle di *cross-diffused sentiment* con la matrice di correlazione esistente;

4. aggiungere l'analisi statistica sentiment-prezzo con ritardi temporali, estesa all'interazione con gli indicatori tecnici (Sezione 4.6);
5. costruire un backtester elementare prima di passare ai modelli predittivi.

Il prototipo dimostra la fattibilità della catena *raccolta* $\rightarrow$ *persistenza* $\rightarrow$ *decay* $\rightarrow$ *visualizzazione*; le priorità elencate sono sviluppate, con le corrispondenti domande di ricerca, nel Capitolo 5.

5 Direzioni future

Questo capitolo delinea le direzioni di sviluppo più promettenti, scientifiche e applicative: l'applicativo fornisce l'infrastruttura di dati e validazione su cui le domande di ricerca possono essere testate empiricamente.

5.1 Direzioni per la ricerca

5.1.1 Stima empirica del parametro di decay

Nel prototipo l'emivita del relevance score è configurabile (default: 7 giorni) ma non stimata dai dati. Una prima domanda a basso costo sperimentale è la stima ottimale di h , selezionando il valore che massimizza la correlazione ritardata tra KPI di sentiment e rendimenti successivi, per titolo o settore. L'ipotesi verificabile è che l'emivita informativa non sia costante, ma vari con capitalizzazione, copertura mediatica e regime di mercato—un risultato autonomo rispetto al decay fisso dei provider commerciali.

5.1.2 Diffusione semantica: dalla PDE alla soluzione discreta

Il modello proposto. Si rappresenti ogni contenuto informativo come un punto x di uno spazio semantico (lo spazio degli embedding), e sia $R(x, t)$ la rilevanza attiva in quel punto al tempo t . Il modello proposto estende il decadimento del Capitolo 3 con un termine di diffusione:

$$\frac{\partial R(x, t)}{\partial t} = \underbrace{D \nabla^2 R(x, t)}_{\text{propagazione}} - \underbrace{\lambda R(x, t)}_{\text{decadimento}}.$$

Perché ha senso. È l'equazione del calore con dissipazione, e l'analogia è sostanziale, non estetica. Il secondo termine è il modello già validato in produzione: in assenza di interazioni, la rilevanza di una notizia si dimezza ogni $h = \ln 2 / \lambda$ giorni. Il primo termine cattura un fatto empirico che il decadimento da solo ignora: l'informazione rilevante per un titolo lo è, in parte, anche per i titoli semanticamente vicini—una notizia sul principale fornitore di un'azienda ne muove il titolo, un downgrade di settore pesa su tutto il settore. Come il calore fluisce da un punto caldo ai punti freddi adiacenti in proporzione alla differenza di temperatura, così la rilevanza fluisce dai titoli molto coperti verso i titoli affini poco coperti, in proporzione al gradiente informativo e alla vicinanza semantica. I due parametri hanno un significato fisico immediato— λ è la velocità dell'oblio, D la permeabilità semantica del mercato—ed è questa leggibilità a distinguere il modello dalle alternative apprese (GNN), i cui pesi non sono interpretabili: il confronto tra i due approcci costituirebbe il contributo scientifico centrale del progetto.

Soluzione discreta. Lo spazio semantico è però noto solo attraverso un numero finito di punti—gli embedding dei ticker—e su un insieme finito di punti l'operatore $-\nabla^2$ ha

un'approssimazione discreta canonica: il Laplaciano di grafo. Si costruisce quindi il grafo di similarità con gli n ticker come nodi, pesi $w_{ij} \geq 0$ dati dalla similarità coseno tra embedding (sogliata, W simmetrica), gradi $d_i = \sum_j w_{ij}$ e $L = \text{diag}(d_i) - W$. La PDE diventa il sistema di equazioni ordinarie

$$\frac{dR}{dt} = -(D L + \lambda I) R, \quad R(t) \in \mathbb{R}^n.$$

Per il sentiment basta un'accortezza: insieme a R si fa evolvere, con lo stesso operatore, il *sentiment pesato* $V = S \cdot R$ (la stessa quantità $s \cdot r$ già usata nel KPI), e si definisce $S_i(t) = V_i(t)/R_i(t)$. Così la rilevanza che si sposta da un titolo all'altro porta con sé il proprio tono, invece di gonfiare quello locale.

Perché il modello si comporta bene. Riscritta nodo per nodo, l'equazione diventa

$$\frac{dR_i}{dt} = D \sum_j w_{ij} (R_j - R_i) - \lambda R_i,$$

e in questa forma le sue proprietà si leggono direttamente. Il flusso tra due titoli è proporzionale alla *differenza* di rilevanza: ciò che esce da un nodo entra esattamente nel vicino, quindi sommando su tutti i nodi i termini di diffusione si elidono a coppie e resta $\frac{d}{dt} \sum_i R_i = -\lambda \sum_i R_i$. La rilevanza complessiva del mercato decade dunque *esattamente come nel modello attuale*: la diffusione redistribuisce, non crea né distrugge. Per lo stesso motivo la rilevanza non può diventare negativa: se R_i si avvicina a zero, ogni differenza $R_j - R_i$ è non negativa e il flusso può solo rientrare. Essendo il sistema lineare, la soluzione si scrive anche in forma chiusa, $R(t) = e^{-\lambda t} e^{-DtL} R(0)$, e per $D = 0$ le equazioni si disaccoppiano riducendosi al decadimento già in produzione ($w = 0,5^{\Delta t/h}$ con $h = \ln 2/\lambda$): il sistema attuale è il caso particolare senza diffusione.

Quanto al sentiment, poiché $V = S \cdot R$ evolve con lo stesso operatore di R , il sentiment di un titolo al tempo t è il rapporto tra due somme costruite con gli stessi coefficienti non negativi—in altre parole, una *media pesata dei sentiment iniziali*, dove il peso di ciascun titolo è la quota di rilevanza che da lì è arrivata. E una media pesata non può mai superare il massimo né scendere sotto il minimo dei valori che media: la diffusione non può fabbricare un sentiment più estremo di quello effettivamente osservato nelle notizie. È la garanzia che conta per un sistema che genera segnali operativi: nessuna amplificazione spuria.

In pratica, popolare `ticker_cross_diffused_sentiment` richiede un aggiornamento al giorno di (R, V) —la soluzione di un piccolo sistema lineare sparso, stabile per qualunque passo temporale—con la matrice W già disponibile dagli embedding. Il caso $D = 0$ fornisce anche il test di validazione naturale: disattivando la diffusione, la nuova pipeline deve riprodurre esattamente i KPI attuali.

5.1.3 Benchmark multi-scorer del sentiment

La delega dello scoring ad Alpha Vantage può diventare un'opportunità: il database contiene decine di migliaia di coppie (articolo, ticker) già etichettate. Si propone un confronto sistematico tra scorer sullo stesso corpus—FinBERT zero-shot, un LLM open-weight via prompting, i punteggi del provider—su due domande: la concordanza inter-rater

e la validità predittiva rispetto ai rendimenti. La conversione *logit-to-score* di FinDPO (Iacovides, Zhou e Mandic 2025) offre punteggi continui e calibrati, confrontabili con la scala $[-1, +1]$ in uso.

5.1.4 Attenzione mediatica come segnale complementare

Il volume di notizie per ticker e topic, già raccolto dalla coverage ingestion, permette di costruire un indice di attenzione mediatica nello spirito dell’Hype Index (Cao, Wunkaew e Geman 2025) senza costi aggiuntivi. L’ipotesi è che i picchi di copertura anticipino volatilità indipendentemente dalla polarità, e che l’interazione $\text{sentiment} \times \text{attenzione}$ superi i due segnali separati.

5.1.5 Interazione tra sentiment e segnali tecnici

Con gli indicatori tecnici (Sezione 4.6) il prototipo espone per ogni titolo un segnale informativo e uno di prezzo; la domanda naturale è se il sentiment abbia *valore predittivo incrementale* rispetto ai segnali tecnici, e se le divergenze anticipino inversioni. Neely et al. (2014) offrono il precedente diretto: gli indicatori tecnici prevedono il premio al rischio con potere comparabile e *complementare* alle variabili macroeconomiche. Il disegno proposto replica quello schema sostituendo alle variabili macro il sentiment: regressioni dei rendimenti su sentiment, segnale tecnico e interazione (Brock, Lakonishok e LeBaron 1992). Il report automatico del Capitolo 4 già classifica ogni titolo come allineato o divergente: le etichette costituiscono le celle del disegno sperimentale, a costo quasi nullo.

5.1.6 Notizie programmate e non programmate

Boudoukh et al. (2019) mostrano che l’impatto delle notizie firm-specific differisce tra eventi *programmati* (earnings, guidance) e *non programmati* (M&A, azioni legali). La pipeline già classifica gli articoli per topic (inclusi `earnings` e `mergers_and_acquisitions`): separare il KPI nei due regimi permetterebbe di verificare se l’emivita informativa h differisca tra notizie attese e sorprese, raffinando la stima empirica del decay proposta sopra—un’analisi resa possibile dallo storico pluriennale del cold store.

5.1.7 Foundation model per serie temporali

La proposta originaria individua nell’LSTM il modello predittivo di riferimento; dal 2024 i modelli fondazionali per serie temporali—Chronos (Ansari et al. 2024), TimesFM (Das et al. 2024)—raggiungono in zero-shot prestazioni comparabili ai modelli supervisionati per singolo dataset. La revisione a basso costo del piano: usare un foundation model come baseline zero-shot e verificare se il condizionamento sul sentiment (covariata o fine-tuning leggero) apporti valore incrementale. Il confronto “LSTM da zero vs. foundation model condizionato sul sentiment” è a sua volta una domanda di ricerca attuale.

5.1.8 Protocollo di backtesting metodologicamente rigoroso

La letteratura critica (Li et al. 2026) mostra che i vantaggi delle strategie LLM svaniscono su orizzonti lunghi e universi ampi, e che i backtest sono esposti a survivorship bias, look-ahead bias e data-snooping. Il backtesting sarà quindi vincolato a un protocollo esplicito: solo informazione disponibile alla data di segnale, benchmark passivi, più regimi di mercato, costi di transazione dichiarati. Per gli scorer LLM va considerato anche il look-ahead bias “parametrico”: la valutazione pulita richiede notizie successive al cutoff di addestramento del modello.

5.2 Direzioni per l’applicativo

Le priorità implementative, per rapporto valore/sforzo:

1. **Scoring interno con FinBERT**: applicazione batch agli articoli in database, con punteggi persistiti accanto a quelli del provider—abilita il benchmark multi-scorer;
2. **Popolamento del cross-diffused sentiment** con il modello della Sezione 5.1.2 e la matrice di correlazione esistente;
3. **Analisi statistica sentiment–prezzo**: correlazioni di Pearson e Spearman con ritardi configurabili (0–5 giorni), al posto del confronto visivo;
4. **Backtester elementare**: strategia long/flat sui dati persistiti, con rendimento cumulato, hit-rate e Sharpe semplificato, nel rispetto del protocollo anti-bias;
5. **Seconda fonte di dati** a basso attrito (RSS o scraping mirato); gli articoli senza scoring del provider sono il banco di prova del modulo FinBERT;
6. **LLM-as-annotator** per un dataset entity-level nello spirito di FinEntity (Yixuan Tang et al. 2023), con revisione manuale a campione, per abilitare il fine-tuning a costi contenuti.

Il vincolo pratico più stringente—uno storico ampio su cui addestrare e validare—è stato rimosso dal cold store (Sezione 4.3.1), che accumula senza limiti di ritenzione il flusso di articoli etichettati dal 2018: fine-tuning e benchmark possono essere pianificati su centinaia di migliaia di esempi.

5.3 Sintesi

Il filo conduttore è la trasformazione del prototipo da strumento di monitoraggio a piattaforma sperimentale: ogni componente applicativa corrisponde a una domanda di ricerca verificabile con i dati già raccolti. L’elemento di maggiore originalità resta la modellazione della rilevanza informativa come campo dinamico che decade e si diffonde nello spazio semantico—ora dotata di formulazione discreta, soluzione in forma chiusa e garanzie di correttezza dimostrate.

Bibliografia

- Ansari, Abdul Fatir et al. (2024). «Chronos: Learning the Language of Time Series». In: *Transactions on Machine Learning Research (TMLR)*. URL: <https://openreview.net/forum?id=gerNCVqqtR>.
- Araci, Dogu (2019). *FinBERT: Financial Sentiment Analysis with Pre-trained Language Models*. arXiv: 1908.10063 [cs.CL]. URL: <https://arxiv.org/abs/1908.10063>.
- Baker, Malcolm e Jeffrey Wurgler (2007). «Investor Sentiment in the Stock Market». In: *Journal of Economic Perspectives* 21.2, pp. 129–152. DOI: 10.1257/jep.21.2.129.
- Bollen, Johan, Huina Mao e Xiaojun Zeng (2011). «Twitter Mood Predicts the Stock Market». In: *Journal of Computational Science* 2.1, pp. 1–8. DOI: 10.1016/j.jocs.2010.12.007.
- Bollinger, John (2001). *Bollinger on Bollinger Bands*. New York: McGraw-Hill.
- Boudoukh, Jacob et al. (2019). «Information, Trading, and Volatility: Evidence from Firm-Specific News». In: *The Review of Financial Studies* 32.3, pp. 992–1033. DOI: 10.1093/rfs/hhy083.
- Brock, William, Josef Lakonishok e Blake LeBaron (1992). «Simple Technical Trading Rules and the Stochastic Properties of Stock Returns». In: *The Journal of Finance* 47.5, pp. 1731–1764. DOI: 10.1111/j.1540-6261.1992.tb04681.x.
- Cao, Zheng, Wanchaloem Wunkaew e Helyette Geman (2025). *The Hype Index: an NLP-driven Measure of Market News Attention*. arXiv: 2506.06329 [q-fin.ST]. URL: <https://arxiv.org/abs/2506.06329>.
- Cristescu, Marian Pompiliu et al. (2023). «Analyzing the Impact of Financial News Sentiments on Stock Prices—A Wavelet Correlation». In: *Mathematics* 11.23, p. 4830. DOI: 10.3390/math11234830.
- Das, Abhimanyu et al. (2024). «A Decoder-Only Foundation Model for Time-Series Forecasting». In: *Proceedings of the 41st International Conference on Machine Learning (ICML)*. URL: <https://proceedings.mlr.press/v235/das24c.html>.
- Devlin, Jacob et al. (2019). «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*, pp. 4171–4186. DOI: 10.18653/v1/N19-1423.
- Duan, Yuejiao, Lanbiao Liu e Zhuo Wang (2021). «COVID-19 Sentiment and the Chinese Stock Market: Evidence from the Official News Media and Sina Weibo». In: *Research in International Business and Finance* 58, p. 101432. DOI: 10.1016/j.ribaf.2021.101432.
- Fischer, Thomas e Christopher Krauss (2018). «Deep Learning with Long Short-Term Memory Networks for Financial Market Predictions». In: *European Journal of Operational Research* 270.2, pp. 654–669. DOI: 10.1016/j.ejor.2017.11.054.
- Gu, Wenjun et al. (2024). «Predicting Stock Prices with FinBERT-LSTM: Integrating News Sentiment Analysis». In: *Proceedings of the 2024 8th International Conference on Cloud and Big Data Computing*. ICCBDC 2024. ACM, pp. 67–72. DOI: 10.1145/3694860.3694870.
- Huang, Allen H., Hui Wang e Yi Yang (2023). «FinBERT: A Large Language Model for Extracting Information from Financial Text». In: *Contemporary Accounting Research* 40.2, pp. 806–841. DOI: 10.1111/1911-3846.12832.
- Iacovides, Giorgos, Wuyang Zhou e Danilo Mandic (2025). «FinDPO: Financial Sentiment Analysis for Algorithmic Trading through Preference Optimization of LLMs». In: *Proceedings of the 6th ACM International Conference on AI in Finance (ICAIF)*. DOI: 10.1145/3768292.3770367.
- Lewis, Patrick et al. (2020). «Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks». In: *Advances in Neural Information Processing Systems (NeurIPS)*. URL: <https://arxiv.org/abs/2005.11401>.
- Li, Weixian Waylon et al. (2026). «Can LLM-based Financial Investing Strategies Outperform the Market in Long Run?» In: *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)*. DOI: 10.1145/3770854.3785702.
- Lo, Andrew W., Harry Mamaysky e Jiang Wang (2000). «Foundations of Technical Analysis: Computational Algorithms, Statistical Inference, and Empirical Implementation». In: *The Journal of Finance* 55.4, pp. 1705–1765. DOI: 10.1111/0022-1082.00265.

- Lopez-Lira, Alejandro e Yuehua Tang (2025). «Can ChatGPT Forecast Stock Price Movements? Return Predictability and Large Language Models». In: *Journal of Financial Economics*. Forthcoming. Preprint: arXiv:2304.07619. URL: <https://arxiv.org/abs/2304.07619>.
- Loughran, Tim e Bill McDonald (2011). «When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks». In: *The Journal of Finance* 66.1, pp. 35–65. DOI: 10.1111/j.1540-6261.2010.01625.x.
- Maia, Macedo et al. (2018). «WWW’18 Open Challenge: Financial Opinion Mining and Question Answering». In: *Companion Proceedings of the The Web Conference 2018*, pp. 1941–1942. DOI: 10.1145/3184558.3192301.
- McGurk, Zachary, Adam Nowak e Joshua C. Hall (2020). «Stock returns and investor sentiment: textual analysis and social media». In: *Journal of Economics and Finance* 44, pp. 458–485. DOI: 10.1007/s12197-019-09494-4.
- Neely, Christopher J. et al. (2014). «Forecasting the Equity Risk Premium: The Role of Technical Indicators». In: *Management Science* 60.7, pp. 1772–1791. DOI: 10.1287/mnsc.2013.1838.
- Ouf, Shimaa et al. (2024). «A Deep Learning-Based LSTM for Stock Price Prediction Using Twitter Sentiment Analysis». In: *International Journal of Advanced Computer Science and Applications* 15.12. DOI: 10.14569/IJACSA.2024.0151223.
- RavenPack (2025a). *Credit News Factors*. <https://www.ravenpack.com/products/edge/factors/credit-news>. “After aggregation ... scores are exponentially smoothed to control factor turnover.”
- (2025b). *Forex Sentiment Factors*. <https://www.ravenpack.com/products/edge/factors/forex-sentiment>. “Exponential smoothing decay — the number of days used to smooth sentiment”.
- (2025c). *News Analytics – Relevance Scoring*. <https://www.ravenpack.com/products/edge/data/news-analytics>. RavenPack fornisce advanced analytics, compreso relevance score esponenziale.
- Shobayo, Olamilekan et al. (2024). «Innovative Sentiment Analysis and Prediction of Stock Price Using FinBERT, GPT-4 and Logistic Regression: A Data-Driven Approach». In: *Big Data and Cognitive Computing* 8.11. ISSN: 2504-2289. DOI: 10.3390/bdcc8110143.
- Tang, Yixuan et al. (2023). «FinEntity: Entity-level Sentiment Classification for Financial Texts». In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Singapore: Association for Computational Linguistics, pp. 15465–15471. DOI: 10.18653/v1/2023.emnlp-main.956.
- Tetlock, Paul C. (2007). «Giving Content to Investor Sentiment: The Role of Media in the Stock Market». In: *The Journal of Finance* 62.3, pp. 1139–1168. DOI: 10.1111/j.1540-6261.2007.01232.x.
- Wan, Xingchen et al. (2021). «Sentiment Correlation in Financial News Networks and Associated Market Movements». In: *Scientific Reports* 11.3062. DOI: 10.1038/s41598-021-82338-6.
- Wang, Mengyu, Shay B. Cohen e Tiejun Ma (2024). «Modeling News Interactions and Influence for Financial Market Prediction». In: *Findings of the Association for Computational Linguistics: EMNLP 2024*, pp. 3302–3314.
- Wilder, J. Welles (1978). *New Concepts in Technical Trading Systems*. Introduce il Relative Strength Index (RSI). Greensboro, NC: Trend Research.
- Wu, Shijie et al. (2023). *BloombergGPT: A Large Language Model for Finance*. arXiv: 2303.17564 [cs.LG]. URL: <https://arxiv.org/abs/2303.17564>.
- Xiao, Yijia et al. (2025). *TradingAgents: Multi-Agents LLM Financial Trading Framework*. arXiv: 2412.20138 [q-fin.TR]. URL: <https://arxiv.org/abs/2412.20138>.
- Xie, Qianqian, Weiguang Han, Zhengyu Chen et al. (2024). «FinBen: A Holistic Financial Benchmark for Large Language Models». In: *Advances in Neural Information Processing Systems 37 (NeurIPS 2024), Datasets and Benchmarks Track*. URL: <https://arxiv.org/abs/2402.12659>.
- Xie, Qianqian, Weiguang Han, Xiao Zhang et al. (2023). «PIXIU: A Comprehensive Benchmark, Instruction Dataset and Large Language Model for Finance». In: *Advances in Neural Information Processing Systems 36 (NeurIPS 2023), Datasets and Benchmarks Track*. URL: https://proceedings.neurips.cc/paper_files/paper/2023/hash/6a386d703b50f1cf1f61ab02a15967bb-Abstract-Datasets_and_Benchmarks.html.
- Yang, Hongyang, Xiao-Yang Liu e Christina Dan Wang (2023). *FinGPT: Open-Source Financial Large Language Models*. arXiv: 2306.06031 [q-fin.ST]. URL: <https://arxiv.org/abs/2306.06031>.